

Классификация банковских обращений с помощью словных и символьных признаков

Алекс Демс | Финальный проект по NLP | Сентябрь 2026

Аннотация

В работе исследуется классификация 77 типов банковских обращений на датасете BANKING77. Сравниваются три варианта разреженных признаков: TF-IDF по словам, TF-IDF по символьным n-граммам и их объединение. Во всех случаях используется линейный SVM. На официальной тестовой выборке объединённая модель получила 90.91% accuracy и 90.92% macro-F1. Для словной модели значения составили 88.12% и 88.12%. Дополнительно проверяется, как качество меняется при ограничении объёма обучающих данных.

1. Введение

Служба поддержки банка должна определить, что именно хочет сделать клиент: узнать статус карты, оспорить операцию, пополнить счёт или решить проблему с переводом. Такие запросы часто короткие и содержат похожие слова, хотя относятся к разным категориям. Поэтому задача требует не только определить общую тему сообщения, но и различать близкие намерения.

Цель работы — проверить, дают ли символьные признаки дополнительную информацию по сравнению со словными признаками. Словные n-граммы хорошо описывают устойчивые фразы, а символьные n-граммы частично переносят информацию между родственными словами и вариантами написания. В качестве классификатора выбран LinearSVC: он быстро обучается и позволяет провести несколько сравнений на CPU.

2. Связанные работы

Wang и Manning [1] показали, что результат текстовой классификации существенно зависит от выбора признаков и варианта линейной модели. Их работа посвящена в основном тональности текста, поэтому опубликованные там значения нельзя напрямую сравнивать с классификацией банковских намерений. Она служит мотивацией для аккуратного сравнения простых признаков.

BERT [2] использует двунаправленные контекстные представления, полученные при предварительном обучении. Sentence-BERT [3] дообучает трансформер для получения компактных представлений предложений. Эти модели могут учитывать смысл и контекст, тогда как в текущей работе рассматриваются только разреженные TF-IDF-признаки.

2.1. BANKING77 и предыдущие результаты

Casapueva и соавторы [4] представили BANKING77 и сравнили несколько энкодеров предложений. В их экспериментах BERT-TUNED получил 93.66% accuracy на полном обучающем наборе, а комбинация USE+ConveRT — 93.36%. Для режима с десятью примерами на класс USE+ConveRT получила 85.19%. Протокол этих экспериментов отличается от текущего: использовались другие модели, предобучение и схема формирования подвыборок.

SetFit [5] — ещё один подход к обучению классификатора при небольшом количестве разметки. Он дообучает sentence transformer на парах текстов, а затем обучает классификационную голову. В этой работе SetFit не запускался; его можно использовать в следующем эксперименте на тех же разбиениях.

3. Данные

Используется открытый англоязычный датасет BANKING77 [4, 6]. В нём 13 083 обращения и 77 намерений. Официальный train содержит 10 003 строки, официальный test — 3 080 строк, по 40 примеров на класс.

Часть данных	Количество	Назначение
Официальный train	10003	Источник для train и validation

Часть данных	Количество	Назначение
Train после удаления дубликатов	9999	Очищенный набор
Training pool	7999	Обучение моделей
Validation	2000	Диагностическая оценка
Официальный test	3080	Финальное сравнение

Для поиска дубликатов текст приводится к нижнему регистру, а последовательности пробелов заменяются одним пробелом. Из train удалены 4 повторяющиеся строки. Затем 20% очищенного train выделяются в validation с сохранением долей классов. В training pool на класс приходится от 28 до 149 примеров. Средняя длина обращения составляет 11.95 слов в train и 10.95 слов в test.

4. Метод

Словная ветка строит униграммы и биграммы и ограничивает словарь 50 000 признаками. Символьная ветка использует n-граммы длины 3–5 внутри границ слов (``char_wb``) и ограничивает словарь 80 000 признаками. Для обеих веток применяется sublinear TF, сглаженный IDF и L2-нормализация. В объединённой модели два вектора соединяются, после чего результат нормализуется ещё раз.

Для частоты признака используется $tf = 1 + \ln(f)$, если $f > 0$. IDF вычисляется как $\ln((1 + N)/(1 + df)) + 1$. LinearSVC обучает 77 линейных классификаторов по схеме one-vs-rest. Используются $C=1$, tolerance 0.0001 и максимум 5 000 итераций. Все модели в одном эксперименте получают одинаковую обучающую подвыборку.

5. Эксперимент

5.1. Настройка

Для каждого ограничения — 10, 30 и 60 примеров на класс — формируются подвыборки с seed 42, 43 и 44. Фактический размер подвыборок составляет 770, 2 308 и 4 537 строк: в некоторых категориях меньше установленного ограничения. Дополнительно один раз обучаются модели на всём training pool из 7 999 строк. В общей сложности выполнено 30 запусков: 3 модели × 3 ограничения × 3 seed и 3 запуска на pool.

Словарь и IDF обучаются заново на каждом обучающем наборе. Test не используется для выбора параметров. Для оценки используются ассигасу и макро-F1. Стандартное отклонение в таблице рассчитано по трём seed. Для сравнения объединённой и словной моделей дополнительно выполнен bootstrap тестовых строк: 2 000 повторных выборов.

5.2. Базовые варианты

Word TF-IDF показывает результат словных признаков без символьной информации. Character TF-IDF проверяет, насколько хорошо классификация работает только по фрагментам слов. Combined TF-IDF объединяет обе ветки и является основным вариантом. В качестве простой проверки можно использовать предсказание самого частого класса: на сбалансированном test его ассигасу равна $1/77$, то есть 1.30%.

6. Результаты

Ограничение / размер	Модель	Ассигасу, %	Макро-F1, %
До 10 / 770	word	67.19 ± 0.87	66.62 ± 0.93
До 10 / 770	char	72.02 ± 0.98	71.44 ± 1.07
До 10 / 770	combined	73.04 ± 0.79	72.52 ± 0.83
До 30 / 2308	word	80.52 ± 0.36	80.33 ± 0.33
До 30 / 2308	char	83.54 ± 0.28	83.38 ± 0.28
До 30 / 2308	combined	84.59 ± 0.36	84.44 ± 0.37
До 60 / 4537	word	85.74 ± 0.56	85.66 ± 0.57
До 60 / 4537	char	87.99 ± 0.29	87.93 ± 0.30
До 60 / 4537	combined	88.76 ± 0.19	88.71 ± 0.21
Pool / 7999	word	88.12	88.12
Pool / 7999	char	89.90	89.87
Pool / 7999	combined	90.91	90.92

Таблица 1. Результаты на официальной тестовой выборке. Для ограниченных режимов указаны среднее значение и выборочное стандартное отклонение по трём seed.




Рисунок 1. Изменение ассигасу при увеличении максимального числа примеров на класс.

Объединённая модель показывает лучший результат во всех трёх ограниченных режимах. При ограничении 10 примеров на класс её преимущество над словной моделью составляет 5.85 п.п. В pool-режиме combined получает 90.91% accuracy, character — 89.90%, word — 88.12%.

6.1. Сравнение с опубликованными результатами

Разница между combined и word в pool-режиме составляет 2.79 п.п. Bootstrap 95% интервал для этой разницы: [2.08; 3.54] п.п. Интервал относится к зафиксированным обученным моделям и не учитывает разброс по обучающим выборкам.

Метод	Условия	Accuracy, %
Word + character SVM	7 999 строк, текущая работа	90.91
BERT-TUNED [4]	Полный train, опубликованный результат	93.66
USE + ConveRT [4]	Полный train, опубликованный результат	93.36
USE + ConveRT [4]	10 примеров на класс, опубликованный результат	85.19

Таблица 2. Опубликованные значения приведены для ориентира. Модели и протоколы не воспроизводились в текущем проекте.

6.2. Анализ ошибок

У combined-модели на pool 280 ошибок. Чаще всего путаются близкие категории: прибытие карты и оценка срока доставки, поддерживаемые валюты и поддерживаемые карты, неудачное и отменённое пополнение. Для таких пар важна цель обращения, а общие ключевые слова часто совпадают.

Текст	Правильный класс	Предсказание
When will I get my card?	card_arrival	card_delivery_estimate
Can I link another card to my account?	card_linking	getting_spare_card
Is it a good time to exchange?	exchange_rate	exchange_charge
There is a fee I do not recognize on my statement.	extra_charge_on_statement	card_payment_not_recognised

В test найдено семь нормализованных текстов, совпадающих с train. Основной результат оставляет official test без изменений. После удаления этих строк accuracy combined равна 90.89% на 3073 примерах. Это не меняет общий вывод.

7. Заключение

В работе реализована и проверена модель классификации банковских обращений на BANKING77. Объединение словных и символьных TF-IDF-признаков дало 90.91% ассурасу и 90.92% macro-F1 на официальном test, превывсив оба варианта с одной веткой. Символьные признаки особенно заметны при небольшом количестве обучающих примеров.

Выводы относятся к одному англоязычному датасету и не показывают поведение модели за пределами банковского домена. Для pool выполнен один запуск, поэтому разброс в этом режиме не оценивался. Следующим шагом будет сравнение с замороженным sentence encoder и SetFit на тех же разбиениях, а также отдельная проверка на перефразированиях и ошибках в написании.

Источники

- [1] Wang S., Manning C. D. Baselines and Bigrams: Simple, Good Sentiment and Topic Classification. ACL, 2012. <https://aclanthology.org/P12-2018/>
- [2] Devlin J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT, 2019. <https://aclanthology.org/N19-1423/>
- [3] Reimers N., Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP-IJCNLP, 2019. <https://aclanthology.org/D19-1410/>
- [4] Casanueva I. et al. Efficient Intent Detection with Dual Sentence Encoders. NLP for Conversational AI, 2020. <https://aclanthology.org/2020.nlp4convai-1.5/>
- [5] Tunstall L. et al. Efficient Few-Shot Learning Without Prompts. arXiv:2209.11055, 2022. <https://arxiv.org/abs/2209.11055>
- [6] PolyAI. BANKING77 и task-specific datasets. <https://github.com/PolyAI-LDN/task-specific-datasets>